Hochschule Karlsruhe
University of
Applied Sciences

Fakultät für
Informatik und
Wirtschaftsinformatik

DABI1 · Projektaufgabe

Mercado: Lieferqualität und Kundenservice

Prof. Dr. Peer Küppers, Prof. Dr. Reimar Hofmann

1. Anwendungsfall und Datensatz

Mercado ist ein brasilianischer Online-Marktplatz. Kunden bestellen Produkte von einem oder mehreren Händlern; die Händler versenden die Ware. Die Dateien enthalten rund 99.000 Bestellungen aus 2016–2018, Stammdaten, Bewertungen und Angaben zum Kundenservice. Bewertungstexte sind nicht enthalten.

Welche Dateien brauchen Sie?

Sie müssen nicht alle zwölf Dateien gleichzeitig laden. Beginnen Sie mit den Bestellungen; ergänzen Sie weitere Dateien passend zur jeweiligen Frage. Alle CSV-Dateien liegen im Unterordner `data/` Ihres Gruppenpakets.

Dateien	Wofür?
`orders.csv`, `customers.csv`	Grundlage: Liefertermine, Kunden und Kundenstandorte.
`items.csv`, `sellers.csv`, `reviews.csv`	Bestellpositionen, Händlerstandorte und Bewertungen; erforderlich für Frage 1.
`products.csv`, `categories.csv`	Produktangaben prüfen und bereinigen (2.1a); auch für eigene Produktanalysen.
`service_observation.csv`	Automatische Nachrichten und anschließende Beschwerden; Frage 2.
`pilot_support.csv`, `service_experiment.csv`	Zwei Tests persönlicher Kundenbetreuung; Frage 3.
`payments.csv` · **optional**	Zahlungsarten und Zahlbeträge; nur für eine passende eigene Frage.
`geolocation.csv` · **optional**	Karten und geschätzte Entfernungen; für die Pflichtfragen nicht nötig.

Zehn Dateien werden für die Pflichtaufgaben verwendet; zwei sind zusätzliche Angebote. Nach der Datenvorbereitung können Sie Frage 1 mit Ihrer Bestelltabelle bearbeiten. Für die Fragen 2 und 3 kommt jeweils die passende Servicedatei hinzu. Die folgenden Seiten beschreiben die einzelnen Tabellen als Nachschlagehilfe.

Dateiformat: CSV, UTF-8, Komma als Spaltentrenner und Punkt als Dezimalzeichen. Leere Felder bedeuten fehlende Werte. Geldbeträge sind in **brasilianischen Real (BRL)** angegeben. Zeitstempel enthalten keine Zeitzone und werden als lokale Zeit verglichen. IDs und fünfstellige Postleitzahlpräfixe sind Text; führende Nullen müssen erhalten bleiben.

Bestellungen und Kunden

orders.csv · eine Zeile je Bestellung

Feld	Bedeutung
`order_id`	Eindeutige Bestellkennung.
`customer_id`	Verweis auf den Kundeneintrag dieser Bestellung.
`order_status`	Bestellstatus, z. B. `delivered`, `canceled`, `shipped`.
`order_purchase_timestamp`	Kaufzeitpunkt.
`order_approved_at`	Zeitpunkt der Bestellfreigabe; kann fehlen.
`order_delivered_carrier_date`	Übergabe an den Transporteur; kann fehlen.
`order_delivered_customer_date`	Tatsächliche Lieferung an den Kunden; kann fehlen.
`order_estimated_delivery_date`	Zugesagter Liefertag; 00:00 bedeutet keine minutengenaue Zusage.

customers.csv · eine Zeile je customer_id

Feld	Bedeutung
`customer_id`	Eindeutige Kennung für den Join zur Bestellung.
`customer_unique_id`	Kundenkennung über mehrere Bestellungen hinweg.
`customer_zip_code_prefix`	Fünfstelliger Postleitzahlpräfix des Kunden.
`customer_city`	Stadt.
`customer_state`	Zweistellige Kennung des brasilianischen Bundesstaats.

`customer_id` bezeichnet den Kundeneintrag einer Bestellung. Wiederkehrende Kunden erkennen Sie an `customer_unique_id`.

Positionen, Zahlungen, Händler und Geodaten

items.csv · eine Zeile je Bestellposition

Der fachliche Schlüssel ist (**`order_id`**, **`order_item_id`**). Eine Bestellung kann mehrere Positionen, Produkte und Händler enthalten.

Feld	Bedeutung
`order_id`	Zugehörige Bestellung.
`order_item_id`	Positionsnummer innerhalb der Bestellung.
`product_id`	Verweis auf das Produkt.
`seller_id`	Verweis auf den Händler.
`shipping_limit_date`	Vorgesehener spätester Versandzeitpunkt der Position.
`price`	Warenpreis der Position in BRL.
`freight_value`	Frachtkosten der Position in BRL.

payments.csv · optional · eine Zeile je Zahlungsvorgang

Der fachliche Schlüssel ist (**`order_id`**, **`payment_sequential`**). Mehrere Zahlungsvorgänge für eine Bestellung sind zulässig.

Feld	Bedeutung
`order_id`	Zugehörige Bestellung.
`payment_sequential`	Laufende Nummer des Zahlungsvorgangs.
`payment_type`	Zahlungsart, z. B. `credit_card`, `boleto`, `voucher`.
`payment_installments`	Anzahl vereinbarter Raten.
`payment_value`	Betrag des Zahlungsvorgangs in BRL.

sellers.csv · eine Zeile je Händler

Feld	Bedeutung
`seller_id`	Eindeutige Händlerkennung.
`seller_zip_code_prefix`	Fünfstelliger Postleitzahlpräfix des Händlers.
`seller_city`	Stadt.
`seller_state`	Zweistellige Bundesstaatkennung.

geolocation.csv · optional · Punkte zu Postleitzahlgebieten

Feld	Bedeutung
`geolocation_zip_code_prefix`	Fünfstelliger Postleitzahlpräfix.
`geolocation_lat`	Breitengrad in Dezimalgrad.
`geolocation_lng`	Längengrad in Dezimalgrad.
`geolocation_city`	Stadt.
`geolocation_state`	Zweistellige Bundesstaatkennung.

Die Datei enthält rund eine Million Punkte und **mehrere Zeilen je Präfix**. Für eine Verknüpfung über Postleitzahlpräfixe bilden Sie zunächst einen repräsentativen Punkt je Präfix, beispielsweise die Median-Koordinaten. Stadtnamen sind kein verlässlicher Schlüssel. Entfernungen zwischen diesen Punkten sind geschätzte Luftlinien und keine gemessenen Transportstrecken. Die Verwendung der Geodaten ist optional.

Produkte und Bewertungen

products.csv · eine Zeile je Produkt

Feld	Bedeutung / Einheit
`product_id`	Eindeutige Produktkennung; Produktnamen sind nicht enthalten.
`product_category_name`	Portugiesische Produktkategorie; kann fehlen.
`product_weight_g`	Gewicht in Gramm.
`product_length_cm`	Länge in Zentimetern.
`product_height_cm`	Höhe in Zentimetern.
`product_width_cm`	Breite in Zentimetern.
`product_photos_qty`	Anzahl der Produktfotos.

Die Produktdatei enthält den verfügbaren Stammdatenstand. Änderungen dieser Angaben im Zeitverlauf sind nicht dokumentiert.

categories.csv · Kategorienreferenz

Feld	Bedeutung
`product_category_name`	Eindeutige portugiesische Kategorie.
`product_category_name_english`	Englische Übersetzung; fehlt für zwei Kategorien.

Die Liste enthält alle 73 nichtleeren Kategorien. Sie kann zur Prüfung und Vereinheitlichung der Produktkategorien verwendet werden.

reviews.csv · eine Zeile je Bewertung

Feld	Bedeutung
`review_id`	Bewertungskennung; nicht global eindeutig.
`order_id`	Zugehörige Bestellung; mehrere Bewertungen sind möglich.
`review_score`	Bewertung von 1 bis 5; größere Werte sind besser.
`review_creation_date`	Zeitpunkt, zu dem die Bewertungsanfrage angelegt wurde.
`review_answer_timestamp`	Zeitpunkt der abgegebenen Bewertung.

Für die Aufgaben verwenden Sie je Bestellung die letzte abgegebene Bewertung: größter `review_answer_timestamp`, bei Gleichstand größter `review_id`. Bewertungen können vor der tatsächlichen Lieferung abgegeben worden sein und Unzufriedenheit während des Wartens ausdrücken.

Kundenservice

Drei Erhebungen zur Kundenbetreuung

Ein Teil der Kunden erhält nach der Lieferung automatisch eine Nachricht. Beispiel:

> Ihre Bestellung wurde zugestellt. Bei Fragen können Sie unseren Kundenservice kontaktieren.

Die Spalte `automatic_notice` hält fest, ob diese Nachricht versandt wurde. Ob sie gelesen wurde, ist nicht erfasst.

Mercado schreibt Kunden nach **verspäteten Lieferungen häufiger** an als nach pünktlichen. Die Auswahl der Empfänger hängt also vom Lieferverlauf ab; es handelt sich nicht um einen randomisierten Test der Nachricht.

Zusätzlich testet Mercado **persönliche Kundenbetreuung**: Ein Mitarbeiter kontaktiert ausgewählte Kunden und bietet Unterstützung bei offenen Anliegen an. In den Testdateien steht, wem dieses Angebot gemacht wurde; die tatsächliche Nutzung der Hilfe ist nicht erfasst.

Jede Datei erfasst, ob zu einer Bestellung **in den sieben Tagen ab** `service_start_at` mindestens eine Beschwerde eingereicht wurde. Für jeden Eintrag liegen Angaben für den gesamten siebentägigen Zeitraum vor. Berechnen Sie den Beschwerdeanteil für jede Datei separat: den Anteil ihrer Einträge mit `complaint_7d = 1`. Die Dateien betreffen unterschiedliche Zeitpunkte und teilweise dieselben Kunden; führen Sie sie deshalb nicht zu einer gemeinsamen Beschwerdestatistik zusammen.

Datei	Beginn und Ablauf
`service_observation.csv`	Am Liefertag: automatische Nachricht; häufiger nach verspäteten als nach pünktlichen Lieferungen.
`pilot_support.csv`	Acht Tage nach Lieferung: kleiner Test bei 40 verspätet belieferten Kunden; zufällig erhalten 20 persönliche Hilfe angeboten, 20 nicht.
`service_experiment.csv`	16 Tage nach Lieferung: größerer Test derselben Betreuung. Unter den pünktlich und den verspätet belieferten Kunden erhält jeweils etwa die Hälfte zufällig ein Hilfsangebot.

service_observation.csv · eine Zeile je geeigneter Bestellung

Feld	Bedeutung
`order_id`	Eindeutige Bestellung.
`service_start_at`	Beginn des siebentägigen Beobachtungszeitraums.
`automatic_notice`	1 = automatische Nachricht versandt, 0 = keine Nachricht.
`complaint_7d`	1 = mindestens eine Beschwerde in diesen sieben Tagen, 0 = keine.

pilot_support.csv und service_experiment.csv · jeweils eine Zeile je Kunde

Feld	Bedeutung
`order_id`	Ausgewählte Bestellung des Kunden.
`customer_unique_id`	Bestellübergreifende Kundenkennung; je Datei eindeutig.
`service_start_at`	Beginn des jeweiligen Tests und Beschwerdefensters.
`assigned_support`	1 = persönliche Hilfe angeboten, 0 = kein Angebot (Vergleichsgruppe).
`complaint_7d`	1 = mindestens eine Beschwerde in diesen sieben Tagen, 0 = keine.

Der größere Test verwendet je Kunde die erste geeignete Bestellung nach Kaufzeitpunkt; bei Gleichstand entscheidet `order_id` aufsteigend. Geeignet sind gelieferte Bestellungen mit tatsächlichem und zugesagtem Liefertermin sowie gültiger letzter Bewertung. Im Pilot sind nur verspätete Lieferungen enthalten.

2. Ihr Beratungsauftrag

Ihre Gruppe ist ein Team einer Data-Science-Beratung. Mercado möchte die Lieferqualität besser verstehen und seine Kundenbetreuung verbessern. Drei Stakeholder erwarten Antworten:

- **Logistikleitung:** Wo dauern Lieferungen lange? Welche Rolle spielen Händlerstandorte, Warenkörbe und Frachtkosten für die Lieferqualität?
- **Serviceleitung:** Was hängt mit schlechten Bewertungen und Beschwerden zusammen? Soll Mercado seine automatischen Nachrichten verändern?
- **Geschäftsführung:** Hilft eine zusätzliche persönliche Kundenbetreuung so deutlich, dass Mercado sie weiter ausbauen sollte?

Bereiten Sie die Analysen in einem Jupyter Notebook auf. Die Stakeholder sollen Fragen, Grafiken und Schlussfolgerungen beim Durchscrollen verstehen; der Code soll für andere Data Scientists nachvollziehbar bleiben.

2.1 Daten vorbereiten

Dateien: `orders.csv`, `customers.csv`, `items.csv`, `sellers.csv`, `reviews.csv`; für die Produktprüfung zusätzlich `products.csv` und `categories.csv`. Die drei Servicedateien werden erst für die Beschwerden und Betreuungstests benötigt.

a) Prüfen Sie Datentypen, Schlüssel, fehlende Werte, Kategorien und plausible Größenordnungen. Bereinigen Sie begründet; ungewöhnliche Werte sind nicht automatisch Fehler. Halten Sie die wichtigsten Befunde und Entscheidungen kurz fest und zeigen Sie an einer Kennzahl die Auswirkung einer Bereinigung.

b) Erstellen Sie für 3.1–3.3 **zusätzlich eine Tabelle mit einer Zeile je Bestellung**. So zählt beim Bewertungsvergleich jede Bestellung einmal, unabhängig von ihrer Positionszahl. Fassen Sie Positionen je `order_id` zusammen (Positionszahl, Warenwert, Frachtkosten) und wählen Sie eine Bewertung je Bestellung. **Erhalten Sie die bereinigte Positionstabelle für Analysen einzelner Produkte oder Händler.** Verknüpfen Sie Bestellungen und Kunden über `customer_id`, Positionen und Bewertungen über `order_id`, Händler über `seller_id`. Optionale Zahlungen ebenfalls je Bestellung zusammenfassen. Für die konkreten Fragen verwenden Sie gelieferte Bestellungen mit tatsächlichem und zugesagtem Liefertermin und gültiger letzter Bewertung von 1 bis 5. Nennen Sie die verbleibende Fallzahl.

c) Entwickeln Sie folgende Merkmale und mindestens **ein eigenes**, fachlich nützliches Merkmal. Nennen Sie jeweils, ab wann die Information verfügbar ist.

Merkmal	Definition
Schlechte Bewertung	Letzte Bewertung höchstens 2.
Lieferdauer	Tatsächlicher Lieferzeitpunkt minus Kaufzeitpunkt, in Tagen. Gruppen: ≤ 7, > 7 bis 14, > 14 bis 21 und > 21 Tage.
Verspätung	Kalendertag der Lieferung liegt nach dem zugesagten Liefertag.
Versand zwischen Bundesstaaten	Mindestens ein Händler sitzt in einem anderen Bundesstaat als der Kunde.
Warenkorb / Fracht	Positionszahl, Warenwert, Frachtkosten und Anteil der Frachtkosten an Warenwert plus Frachtkosten.

2.2 Zwei kurze Data Stories

Dateien: Nutzen Sie Ihre Bestelltabelle aus 2.1 für Lieferungen, Warenkörbe und Bewertungen. Für Beschwerden ergänzen Sie `service_observation.csv` über `order_id`. Produkte/Kategorien können eine eigene Frage ergänzen; Zahlungen und Geodaten bleiben optional.

Erstellen Sie zwei Abschnitte: **EDA für die Logistikleitung** (Lieferungen und Warenkörbe) und **EDA für die Serviceleitung** (Bewertungen und Beschwerden). Wählen Sie selbst aussagekräftige Verteilungen, Vergleiche und Entwicklungen. Untersuchen Sie dabei mindestens eine Frage mit Ihrem eigenen Merkmal. Karten und Entfernungen sind optional.

3. Konkrete Fragen der Stakeholder

Gliedern Sie Ihr Notebook entsprechend den Fragen 3.1–3.3. Nutzen Sie Tabellen, Grafiken und kurze fachliche Antworten. Berichten Sie Fallzahlen, Anteile und Unterschiede (z. B. in Prozentpunkten). Beurteilen Sie die Aussagekraft mit passenden Konfidenzintervallen, Tests oder einer Überprüfung auf anderen Daten. Untersuchen Sie die Zusammenhänge manuell; keine automatische Struktursuche.

3.1 Frage 1 · Versand und Bewertungen

Dateien: Bestelltabelle aus 2.1 (`orders.csv`, `customers.csv`, `items.csv`, `sellers.csv`, `reviews.csv`). Weitere Dateien sind nicht nötig.

a) Unterscheidet sich der Anteil schlechter Bewertungen zwischen Lieferungen innerhalb und zwischen Bundesstaaten?

b) Wie hängt die Lieferdauer mit dem Versand innerhalb/zwischen Bundesstaaten zusammen? Wie hängt sie mit dem Anteil schlechter Bewertungen zusammen?

c) Vergleichen Sie die Bewertungsanteile erneut, jetzt **innerhalb jeder der vier Lieferdauergruppen**. Wird der Zusammenhang aus a) durch die Lieferdauer vollständig, teilweise oder kaum erklärt? Begründen Sie Ihre Antwort.

d) Prüfen Sie die Interpretation getrennt für die Kaufjahre **2017 und 2018**. Welche Empfehlung würden Sie der Logistikleitung geben? Lässt sich aus den Beobachtungen bereits eine wirksame Veränderung der Versandorganisation ableiten?

3.2 Frage 2 · Automatische Nachricht nach Lieferung

Dateien: `service_observation.csv` und aus Ihrer Bestelltabelle nur `order_id` und das Merkmal Verspätung. Verbinden Sie beide über `order_id`.

Die Serviceleitung vermutet, dass die Nachricht nach der Lieferung Kunden erst auf die Idee bringt, sich zu beschweren. Prüfen Sie diese Vermutung.

a) Vergleichen Sie den Anteil der Bestellungen mit mindestens einer Beschwerde: mit automatischer Nachricht gegenüber ohne Nachricht. Jede Bestellung zählt als ein Fall.

b) Hängt der Nachrichtenversand mit Verspätungen zusammen? Hängen Beschwerden mit Verspätungen zusammen?

c) Vergleichen Sie die Beschwerdeanteile mit/ohne Nachricht getrennt für pünktliche und verspätete Lieferungen. Wie verändert sich die Interpretation aus a)? Erklärt die Verspätung den Zusammenhang vollständig, teilweise oder kaum?

d) Beurteilen Sie den Vorschlag, die Nachrichten abzuschaffen. Was können Sie anhand dieser Beobachtungen begründen? Sind weitere Untersuchungen notwendig?

3.3 Frage 3 · Persönliche Kundenbetreuung

Dateien: `pilot_support.csv` und `service_experiment.csv`; jeweils **getrennt** über `order_id` an Ihre Bestelltabelle (`order_id`, Verspätung) anbinden.

a) Werten Sie zunächst `pilot_support.csv` aus: Beschwerdeanteile mit/ohne Angebot, Fallzahlen, Anteilsdifferenz und deren Aussagekraft. Würden Sie allein auf dieser Grundlage einen Ausbau empfehlen?

b) Werten Sie `service_experiment.csv` aus: Beschwerdeanteile mit/ohne Hilfsangebot, insgesamt und getrennt nach Verspätung. Berechnen Sie die Anteilsdifferenz (mit minus ohne Angebot) mit geeignetem 95-%-Konfidenzintervall. Vergleichen Sie den Pilot mit der Verspätungsgruppe des größeren Tests.

c) Welche Empfehlung geben Sie der Geschäftsführung? Erklären Sie, welche Aussage die zufällige Auswahl der Empfänger eines Hilfsangebots zur **zusätzlichen Betreuung an Tag 16** ermöglicht. Inwieweit beantwortet dieser Test die Frage nach der Wirkung der automatischen Nachrichten?

4. Dashboard und Abgabe

4.1 Business Dashboard mit Power BI

Dateien: Nutzen Sie Ihre bereinigten Tabellen aus 2.1. Je nach Zielgruppe ergänzen Sie die Servicedatei aus 3.2 oder die Testdateien aus 3.3; alle zwölf Rohdateien in Power BI zu laden ist nicht erforderlich.

Wählen Sie **Logistikleitung, Serviceleitung oder Geschäftsführung** als Zielgruppe. Definieren Sie kurz deren Informationsbedarf und setzen Sie ein prototypisches Dashboard mit **höchstens zwei Seiten** um.

- Nutzen Sie passende Kennzahlen, Visualisierungen und Filter, die konkrete Fragen dieser Zielgruppe beantworten. Sie dürfen auf Ihren Notebookanalysen aufbauen; Übersichtlichkeit und verständliche Aussagen stehen im Vordergrund.
- Machen Sie Bezugsgrößen und Fallzahlen nachvollziehbar. Halten Sie die drei Erhebungen zur Nachbetreuung getrennt.
- Prüfen Sie, dass Notebook und Power BI bei gleichen Filtern dieselben Kennzahlen liefern. Beschreiben Sie Ihr Datenmodell und wichtige Kennzahlen kurz.

Erstellen Sie dazu **Business Dashboard – Annahmen**, maximal eine PDF-Seite: gewählter Stakeholder, Informationsbedarf, wesentliche Annahmen und begründeter Handlungsbedarf. Eine Karte ist keine Pflicht.

4.2 Einzureichende Dateien

Geben Sie nur die Daten mit ab, die Ihr Notebook und Ihr Dashboard tatsächlich benötigen.

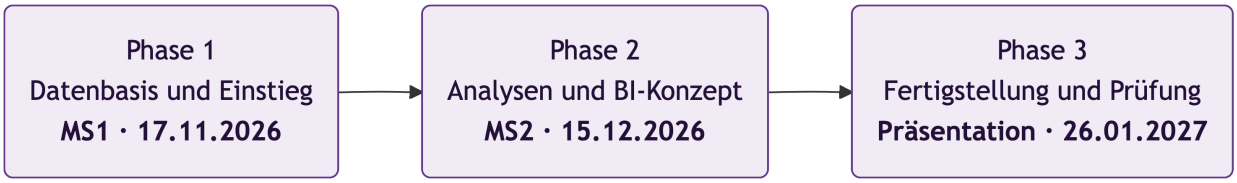
Datei	Inhalt
Jupyter Notebook	Datenvorbereitung, beide Data Stories, Antworten auf die drei Stakeholderfragen; Ergebnisse und kurze Interpretationen direkt bei den Tabellen und Grafiken.
Power-BI-Projekt	Dashboard mit höchstens zwei Seiten und nachvollziehbarem Datenmodell.
Business Dashboard – Annahmen.pdf	Zielgruppe, Informationsbedarf, Annahmen und Empfehlung; höchstens eine Seite.
Benötigte Daten und kurze Startanleitung	Reproduzierbare Bereinigung und BI-Daten; Pakete und Ausführungsreihenfolge.

Das Notebook muss von Anfang bis Ende ausführbar sein. Erhalten Sie die Rohdateien; Korrekturen erfolgen nachvollziehbar im Code. Interpretieren Sie fehlende Präzision nicht als Nachweis fehlender Wirkung und einen nichtsignifikanten Test nicht als Beweis von Unabhängigkeit. Berücksichtigen Sie bei den Bestellanalysen, dass einzelne Kunden mehrfach bestellen können.

Bei KI-Unterstützung treffen Sie zuerst ein eigenes fachliches Urteil, prüfen Vorschläge und übernehmen oder korrigieren sie begründet. Dokumentieren Sie wesentliche KI-Beiträge knapp. Sie verantworten Code und Schlussfolgerungen.

4.3 Projektphasen und Meilensteine

Die Bearbeitung gliedert sich in drei Phasen mit zwei Meilensteingesprächen und einer Abschlusspräsentation. Die Meilensteine dienen der fachlichen Rückmeldung und der Planung der nächsten Schritte. Zeigen Sie jeweils einen **im Code umgesetzten und erläuterten Arbeitsstand**. Eine abschließende redaktionelle Aufbereitung wird erst für die Endabgabe nach 4.2 erwartet.



Phase 1 · Datenbasis und Einstieg bis MS1 am 17.11.2026

Zum ersten Meilenstein, nach etwa vier Wochen, zeigen Sie:

- **Datenverständnis und Vorbereitung (2.1):** Die benötigten Tabellen, Auswertungseinheiten und Schlüssel sind verstanden; die Datenvorbereitung einschließlich der geforderten Merkmale und mindestens eines eigenen Merkmals ist umgesetzt. Zeigen Sie zentrale Qualitätsbefunde, begründete Bereinigungen und deren Auswirkung an einer Kennzahl. Belegen Sie anhand von Fallzahlen und Schlüsselprüfungen, dass Ihre Bestelltabelle jede Bestellung einmal enthält und Joins keine unbeabsichtigte Vervielfachung erzeugen.
- **Notebook und erste Analyse:** Die Gliederung für 2.1, 2.2 und 3.1–3.3 steht. Für mindestens eine selbst gewählte Frage aus 3.1–3.3 liegen bis einschließlich Teilaufgabe b) erste berechnete Ergebnisse vor. Erläutern Sie Vorgehen, Fallzahlen und vorläufige Interpretation; noch offene methodische Fragen dürfen Gegenstand des Gesprächs sein.
- **Zusammenarbeit und KI-Einsatz:** Zuständigkeiten, Zusammenführung der Beiträge und gegenseitige Prüfung sind vereinbart. Eine Spezialisierung, etwa nach Stakeholderfragen, ist möglich. Erläutern Sie bei KI-Einsatz, wie Sie Vorschläge fachlich prüfen und wesentliche Beiträge dokumentieren.

Phase 2 · Analysen und Dashboardkonzept bis MS2 am 15.12.2026

Zum zweiten Meilenstein zeigen Sie den weiterentwickelten Stand:

- **Zwei Data Stories (2.2):** Für Logistik- und Serviceleitung liegt jeweils ein erster zusammenhängender Entwurf mit passenden Grafiken und kurzen fachlichen Aussagen vor; das eigene Merkmal wird in einer Frage untersucht.
- **Zwei vollständige Analyseentwürfe:** Zwei selbst gewählte Fragen aus 3.1–3.3 sind mit allen Teilaufgaben bearbeitet. Zeigen Sie berechnete Ergebnisse, eine passende Beurteilung ihrer Aussagekraft und vorläufige Empfehlungen mit den jeweiligen Interpretations- und Kausalitätsgrenzen.
- **Dashboardkonzept (4.1):** Zielgruppe, Informationsbedarf, wesentliche Kennzahlen, Filter und Datenquellen sind festgelegt. Zeigen Sie eine Seitenskizze oder einen ersten Power-BI-Prototyp und erläutern Sie das geplante Datenmodell sowie den Kennzahlenabgleich mit dem Notebook.
- **Plan für den Abschluss:** Benennen Sie die Restarbeit an der dritten Stakeholderfrage, am Dashboard und an der Abgabe sowie deren Zuständigkeiten. Zeigen Sie, wie Sie die Rückmeldung aus MS1 aufgegriffen haben.

Phase 3 · Fertigstellung und Abschlusspräsentation am 26.01.2027

Vervollständigen und prüfen Sie alle Aufgaben aus 2.1–4.1. Bereiten Sie die Dateien gemäß 4.2 zur Abgabe vor. Prüfen Sie insbesondere die vollständige Ausführbarkeit des Notebooks, die Übereinstimmung der Kennzahlen in Notebook und Power BI bei gleichen Filtern sowie die Nachvollziehbarkeit Ihrer Annahmen, Methoden und Empfehlungen.

Präsentieren Sie Ihre wichtigsten Ergebnisse aufbereitet für sowie gerichtet an die Stakeholder und demonstrieren Sie das Dashboard. Begründen Sie die Empfehlungen anhand Ihrer Analysen und erläutern Sie deren Aussagekraft und Grenzen.

Jedes Gruppenmitglied muss am Ende das gesamte Projekt erklären können: Datenvorbereitung und Code, methodische Entscheidungen, Ergebnisse und Interpretationen sowie Dashboard und Empfehlungen. Planen Sie bei Arbeitsteilung deshalb Zeit für gegenseitige Erläuterung und gemeinsame Prüfung ein.

Organisation der Gespräche und Präsentationen

Die beiden Meilensteingespräche finden **online und einzeln je Gruppe** statt. Pro Gruppe stehen **insgesamt 15 Minuten einschließlich Rückfragen und Feedback** zur Verfügung. Bereiten Sie einen kompakten Einblick in Notebook und gegebenenfalls Dashboardskizze vor. Als Orientierung: etwa acht Minuten für den Arbeitsstand, die übrige Zeit für Diskussion und nächste Schritte. Wählen Sie dafür zentrale Befunde aus und halten Sie den zugehörigen Code für Rückfragen bereit.

Für MS1 und MS2 sind voraussichtlich jeweils der 4. und 5. Block vorgesehen. Die Abschlusspräsentationen finden ebenfalls einzeln je Gruppe statt, ohne weitere Zuhörer und ohne die anderen Gruppen; voraussichtlich im 3. und 4. Block. Die genaue Gruppeneinteilung, die Online-Zugänge für die Meilensteine sowie Dauer und Ablauf der Abschlusspräsentation werden gesondert bekannt gegeben. Abgabetermin und Abgabeweg für die Dateien nach 4.2 werden ebenfalls gesondert mitgeteilt.

Datenquelle und Lizenz

Grundlage: Olist / André Sionek, **Brazilian E-Commerce Public Dataset by Olist**: https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

Lizenz: **CC BY-NC-SA 4.0**: https://creativecommons.org/licenses/by-nc-sa/4.0/.

Für die Lehrfallstudie aufbereitet und ergänzt. Bei einer Weitergabe Quelle, Lizenz und eigene Änderungen nennen; keine kommerzielle Nutzung, Weitergabe von Bearbeitungen unter derselben Lizenz.